

Examen_Miranda_Belmonte_Hairo

Miranda Belmonte Hairo

8 de octubre de 2016

EJERCICIO 1

simbolos seleccionados: #Dow Jones Industrial Average--^DJI #Nikkei 225 --^N225 (tokmo japsn) #AEX-INDEX --^AEX (pamses bajos) #IPC---^MXX #CAC 40 (^FCHI) paris

EVALUANDO HECHOS ESTILIZADOS PARA GSPC #generando variable y seleccionando precios ajustados

h:1 precios de las acciones impredecibles

```
library(quantmod)
```

```
getSymbols("^GSPC")
```

```
## [1] "GSPC"
```

```
sp500<-get("GSPC")
```


```
sp500 <- Ad(sp500)
```

```
par(mfrow=c(2,1))
```

```
ret.sp500<-diff(log(sp500))
```

```
plot(ret.sp500, main="retornos sp500")
```

```
plot(sp500, main="sp500")
```




h:2 retornos no correlacionado

```
library(forecast)


ret.sp500<-diff(log(sp500))
par(mfrow=c(1,1))
acf(na.omit(ret.sp500))
```

Series na.omit(ret.sp500)

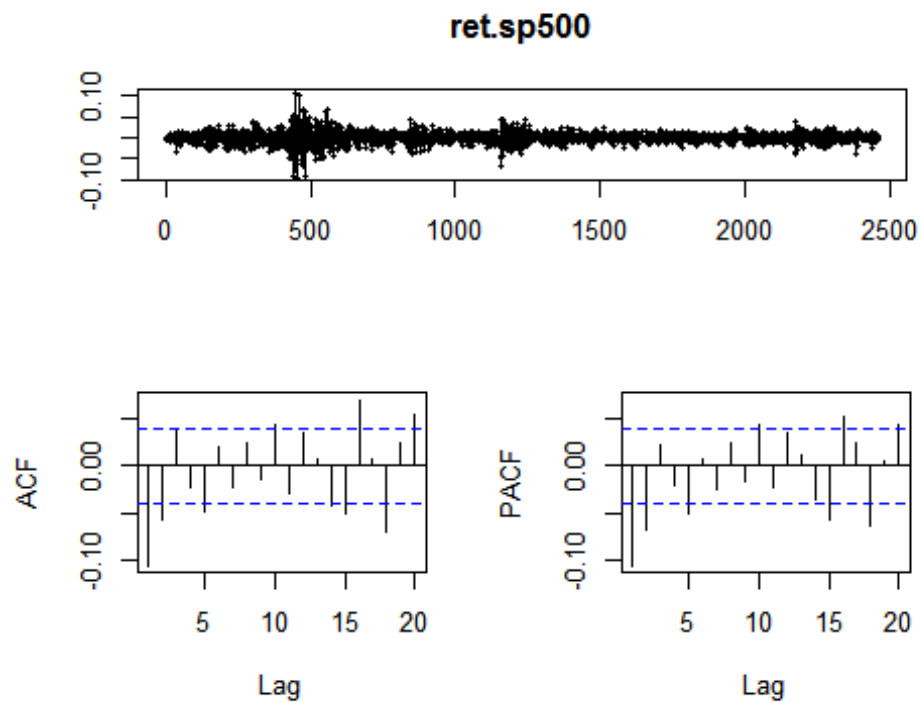


```
pacf(na.omit(ret.sp500))
```

Series na.omit(ret.sp500)




```
tsdisplay(ret.sp500, lag.max = 20)
```




h:3 retornos al cuadrado correlacionados

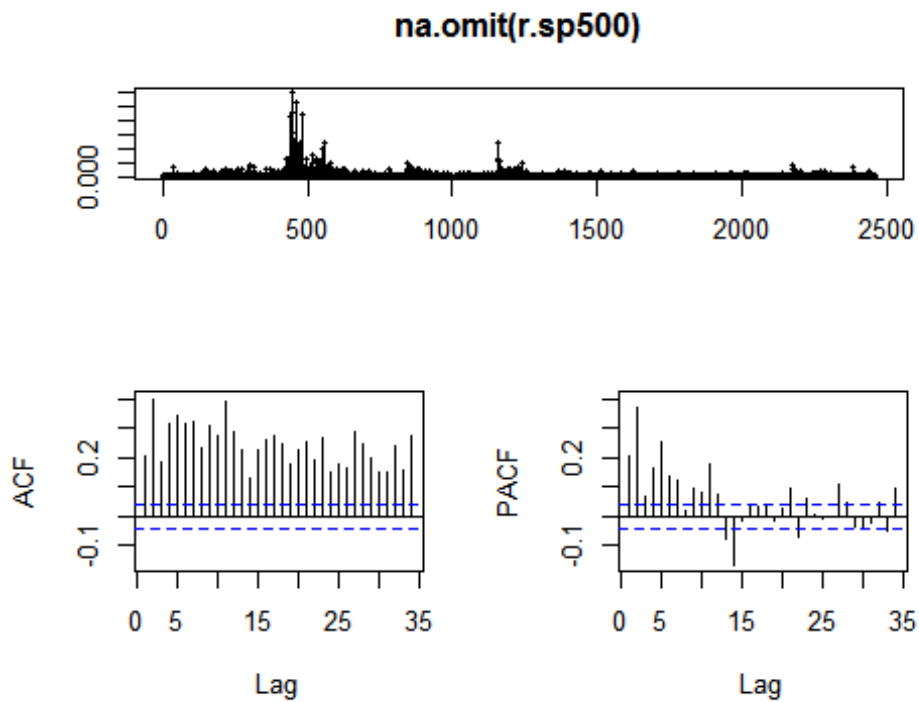
```
r.sp500<-ret.sp500^2  
acf(na.omit(r.sp500))
```



```
pacf(na.omit(r.sp500))
```




```
tsdisplay(na.omit(r.sp500))
```




h:4 clusters de volatilidad

```
par(mfrow=c(1,1))
plot(na.omit(ret.sp500),main="retornos sp500")
```




```
plot(na.omit(r.sp500),main="retornos al cuadrado sp500"))
```

na.omit(r.sp500, main = "retornos al cuadrado sp500")



```
plot(na.omit(abs(ret.sp500),main="retornos en absolutos sp500"))
```


omit(abs(ret.sp500), main = "retornos en absolutos sp500")



podemos observar que tanto en los retornos, sus cuadrados y en valores absolutos es notable los clusters


```
par(mfrow=c(1,1))
acf(na.omit(ret.sp500,main="retornos sp500"),lag.max = 500)
```

Series na.omit(ret.sp500, main = "retornos sp500"



```
acf(na.omit(r.sp500,main="retornos al cuadrado sp500"),lag.max = 500)
```


ries na.omit(r.sp500, main = "retornos al cuadrado s



podemos observar significancia en lags alejados, se nota volatilidad por persistencia de autocorrelación la varianza puede estar condicionada a sus valores pasados lo que determina clusters

```
umbral <- quantile(na.omit(ret.sp500),0.95)
menor.umbr<-as.numeric(ret.sp500>umbral)
agrupa.rets<-menor.umbr
as.ts(agrupa.rets)


par(mfrow=c(1,1))
plot(agrupa.rets)
```



LOS VALORES SE AGLOMERAN

```
umb<-function(IC){
  umbral <- quantile(na.omit(ret.sp500),IC)
  menor.umbr<-as.numeric(ret.sp500>umbral)
  agrupa.rets<-menor.umbr
  as.ts(agrupa.rets)
  par(mfrow=c(1,1))
  plot(agrupa.rets)
}

umb(.99)
```





LOS VALORES SE AGLOMERAN

h:5 leptocurtosis


```
par(mfrow=c(1,1))
plot(density(na.omit(ret.sp500), main="Densidad de los retornos del
sp500"))
z<-seq(-5,5,len=1000)
x<-dnorm(z,mean=mean(ret.sp500,na.rm=T),sd=sd(ret.sp500,na.rm=T))
lines(z,x,col='red',lty=2,lwd=2)
```

It(x = na.omit(ret.sp500, main = "Densidad de los retc



qq plot para determinar fat tails

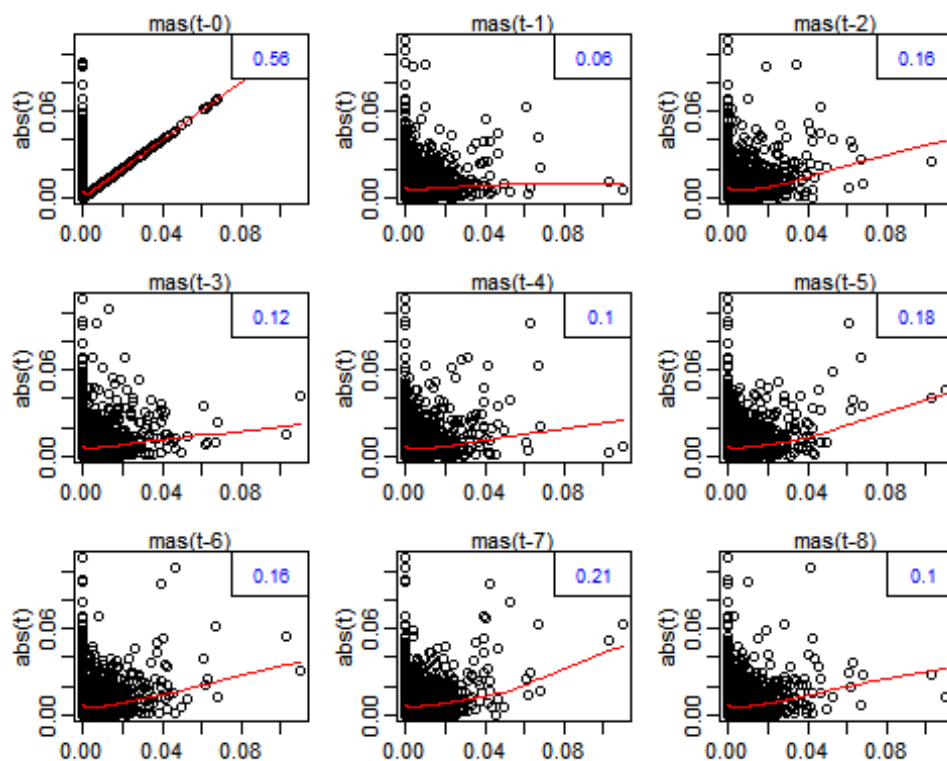
```
w<-na.omit(coredata(ret.sp500))  
qqnorm(w)  
qqline(w,col='red',lty=2)
```



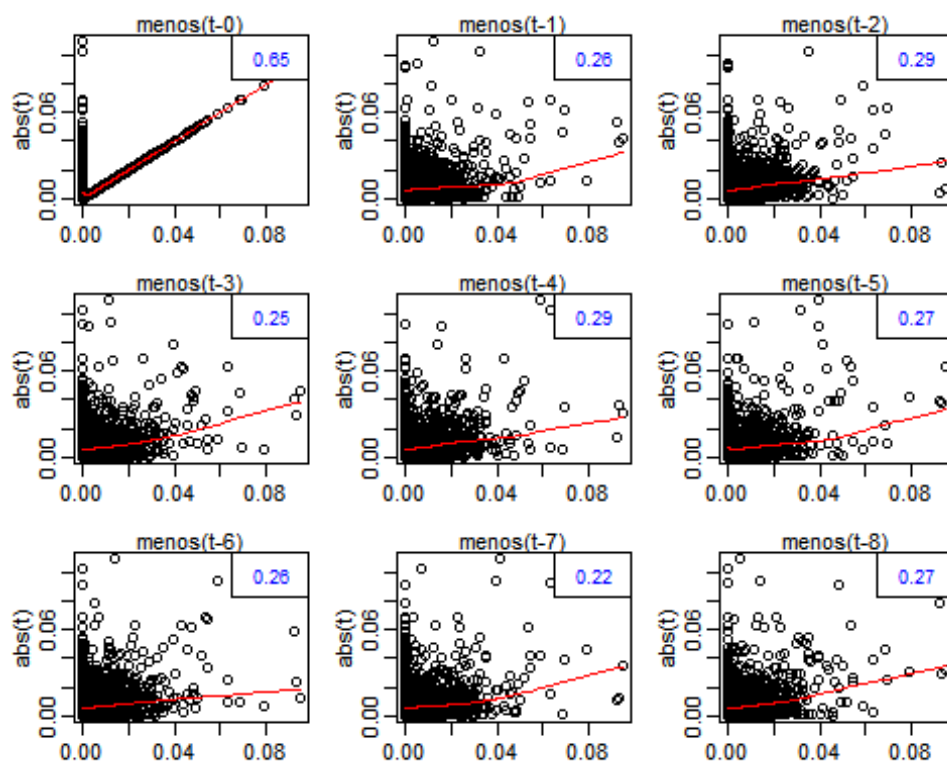
se observa informacisn a los extremos el cual es factor para tener colas anchas

h:6 leverage effect

```
library(astsa)  
  
rets<-function(a){  
  b<-diff(log(Ad(a)))  
  return(b)  
}  
  
dato<-na.omit(ret.sp500)  
mas<-apply.daily(dato,function(a) max(a,0))  
menos<-apply.daily(dato,function(a) -min(a,0))  
abs<-apply.daily(dato,function(a) abs(a))  
lag2.plot(mas,abs,8)
```



`lag2.plot(menos,abs,8)`



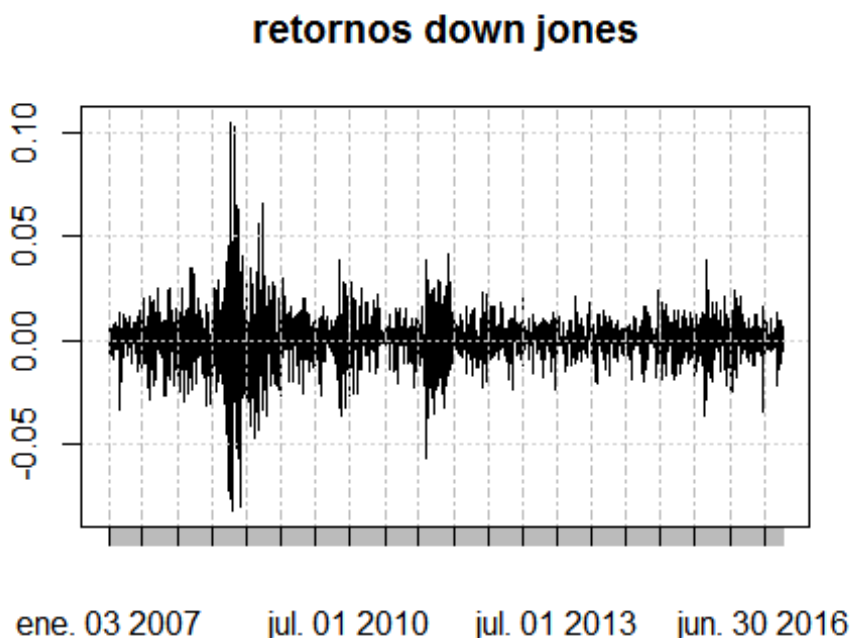
choques negativos y positivos son asimétricos, los positivos hacen que los retornos varíen menos que los negativos

justificación: Retornos se modelan mejor con ruido blanco débil o fuerte? Ruido blanco débil # Ya que su función de autocorrelación de los retornos logarítmicos, # nos muestra valores significativos en sus lags. recordemos que independencia nos indica no correlación, en el cual esto no es el caso. # Con el Plot de la serie podemos ver como un valor elevado le precede otro elevado, indicándonos # un proceso con memoria a lo inmediato, posiblemente por la correlación.

EVALUANDO HECHOS ESTILIZADOS PARA DJI

h:1 precios de las acciones impredecibles

```
getSymbols("^DJI")  
  
## [1] "DJI"  
  
djon<-get("DJI")  
djon<-Ad(djon)  
par(mfrow=c(1,1))  
ret.djon<-diff(log(djon))  
plot(ret.djon, main="retornos down jones")
```



```
plot(djon, main="down jones")
```


down jones



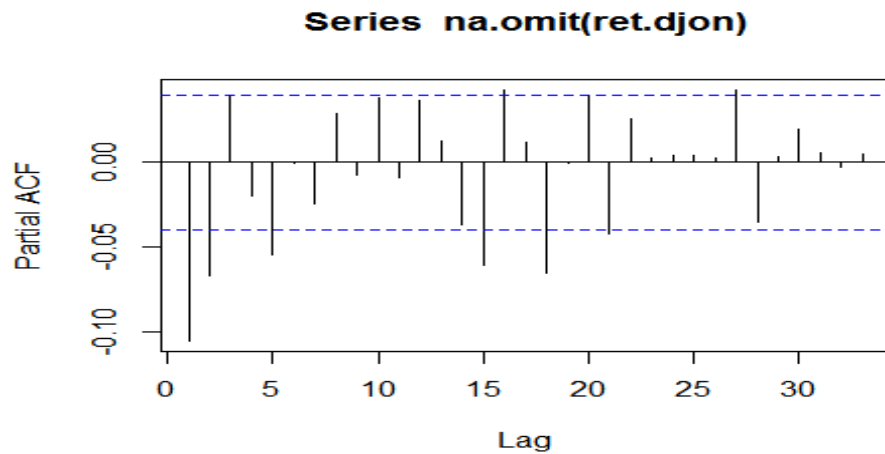
h:2 retornos no correlacionado

```
par(mfrow=c(1,1))  
acf(na.omit(ret.djon))
```


Series na.omit(ret.djon)



```
pacf(na.omit(ret.djon))
```

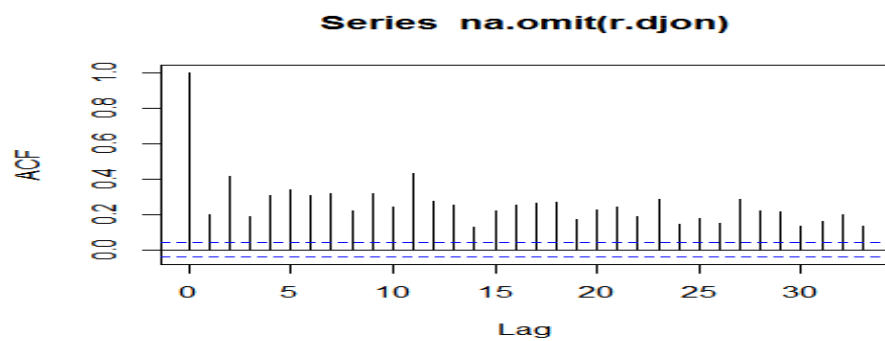


```
tsdisplay(ret.djon, lag.max = 20)
```

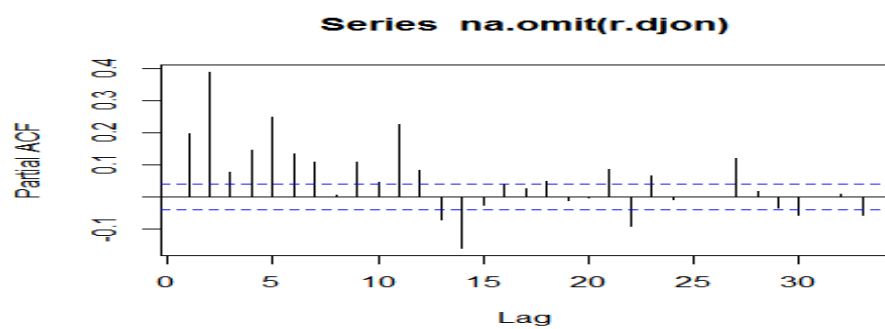


h:3 retornos al cuadrado correlacionados

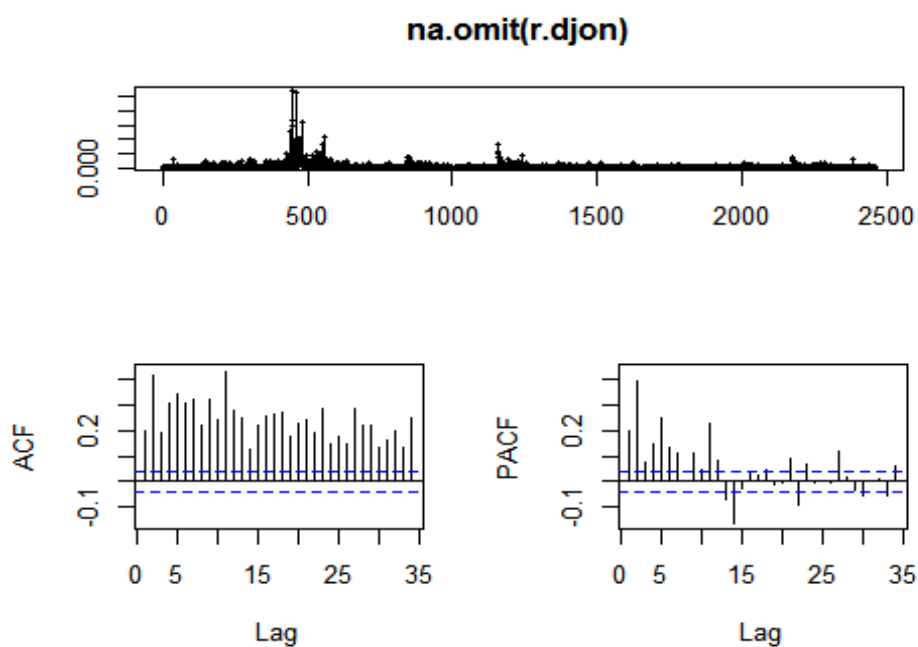
```
r.djon<-ret.djon^2
par(mfrow=c(1,1))
acf(na.omit(r.djon))
```



```
pacf(na.omit(r.djon))
```




```
tsdisplay(na.omit(r.djon))
```



h:4 cloters de volatilidad


```
par(mfrow=c(1,1))  
plot(na.omit(ret.djon,main="retornos down jones"))
```

na.omit(ret.djon, main = "retornos down jones")




```
plot(na.omit(r.djon,main="retornos al cuadrado down jones"))
```

na.omit(r.djon, main = "retornos al cuadrado down joi



```
plot(na.omit(abs(ret.djon),main="retornos en absolutos down jones"))
```


nit(abs(ret.djon), main = "retornos en absolutos dow



podemos observar que tanto en los retornos, sus cuadrados y en valores absolutos es notable los cloters



```
par(mfrow=c(1,1))
acf(na.omit(ret.djon,main="retornos down jones"),lag.max = 500)
```

Series na.omit(ret.djon, main = "retornos down jones")



```
acf(na.omit(r.djon,main="retornos al cuadrado down jones"),lag.max = 500)
```


es na.omit(r.djon, main = "retornos al cuadrado down jones")



podemos observar significancia en lags alejados, se nota volatilidad por persistencia de autocorrelación la varianza puede estar condicionada a sus valores pasados lo que determina clusters

```
umbral2 <- quantile(na.omit(ret.djon),0.95)
menor.umbr2<-as.numeric(ret.djon>umbral2)
agrupa.rets2<-menor.umbr2
as.ts(agrupa.rets2)
```


```
par(mfrow=c(1,1))
plot(agrupa.rets2)
```



LOS VALORES SE AGLOMERAN

```
umb2<-function(IC){
  umbral2 <- quantile(na.omit(ret.djon),IC)
  menor.umbr2<-as.numeric(ret.djon>umbral2)
  agrupa.rets2<-menor.umbr2
  as.ts(agrupa.rets2)
  par(mfrow=c(1,1))
  plot(agrupa.rets2)
}

umb2(.99)
```




LOS VALORES SE AGLOMERAN EN LAS PRIMERAS OBSERVACIONES QUE SALEN DEL INTERVALO

h:5 leptocurtosis


```
par(mfrow=c(1,1))
plot(density(na.omit(ret.djon, main="Densidad de los retornos del down
jones")))
z2<-seq(-5,5,len=1000)
x2<-dnorm(z2,mean=mean(ret.djon,na.rm=T),sd=sd(ret.djon,na.rm=T))
lines(z2,x2,col='red',lty=2,lwd=2)
```

x = na.omit(ret.djon, main = "Densidad de los retornos del down jones")



qq plot para determinar fat tails

```
w2<-na.omit(coredata(ret.djon))
qqnorm(w2)
qqline(w2,col='red',lty=2)
```



se observa informacisn a los extremos el cual es factor para tener colas anchas

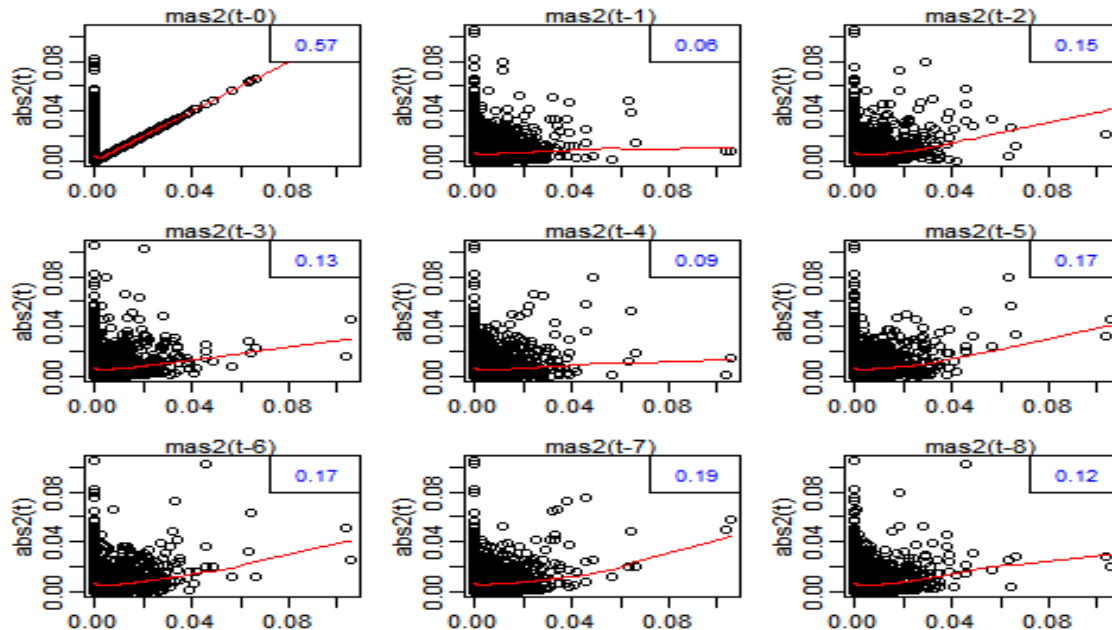
h:6 leverage effect

```
library(astsa)
rets<-function(a){
  b<-diff(log(Ad(a)))
  return(b)
}
```

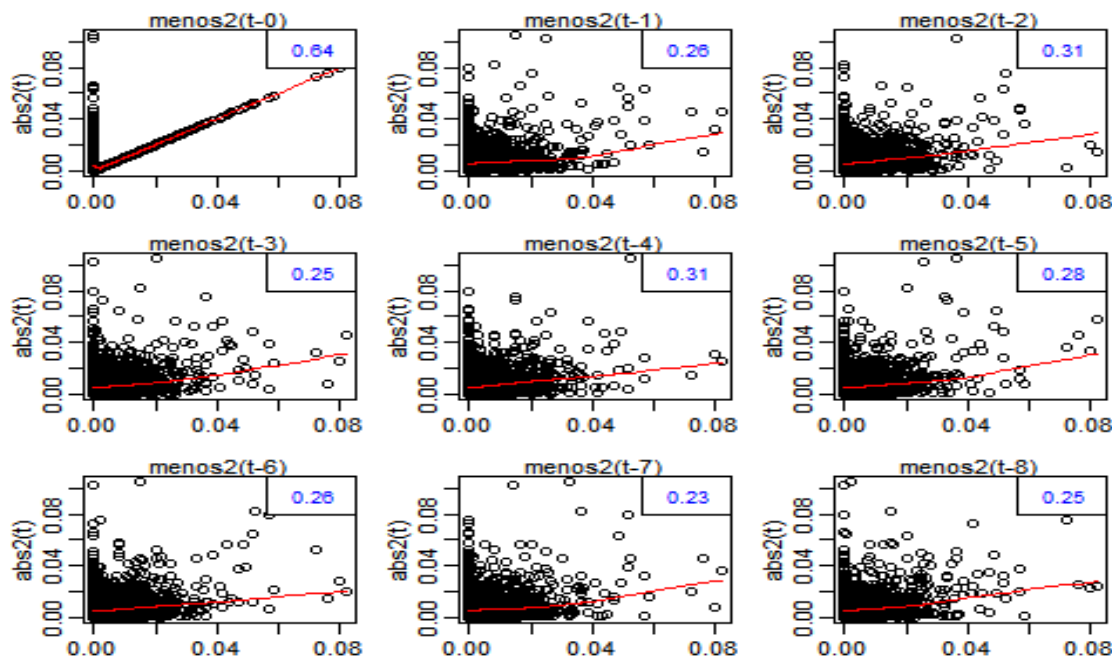
```

dato2<-na.omit(ret.djon)
mas2<-apply.daily(dato2,function(a) max(a,0))
menos2<-apply.daily(dato2,function(a) -min(a,0))
abs2<-apply.daily(dato2,function(a) abs(a))
lag2.plot(mas2,abs2,8)

```



```
lag2.plot(menos2,abs2,8)
```



choques negativos y positivos son asimetricos, los positivos hacen que los retornos varien menos que los negativos

justificaci??n:??Retornos se modelan mejor con ruido blanco debil o fuerte?

Ruido blanco debil

Ya que su funci??n de autocorrelaci?? De los retornos logaritmicos,

Nos muestra un valor significativos en su lag 2. recordemos que independencia nos indica no correlaci??, en el cual est?? no es el caso. #Con el Plot de la serie podemos ver como un valor elevado le precede otro elevado, indicandonos #un proceso con memoria a lo de ayer , posiblemente por la correlaci??n.

EVALUANDO HECHOS ESTILIZADOS PARA ^N225

h:1 precios de las acciones impredecibles

```
getSymbols("^N225")
```

```
## [1] "N225"
```


```
n_225<-get("N225")
```

```
n_225 <- Ad(n_225)
```

```
par(mfrow=c(1,1))
```

```
ret.n225<-diff(log(n_225))
```


```
plot(ret.n225, main="retornos N225")
```




```
plot(n_225, main="N225")
```




```
#h:2 retornos no correlacionado  
acf(na.omit(ret.n225))
```



```
pacf(na.omit(ret.n225))
```




```
tsdisplay(ret.n225, lag.max = 20)
```




h:3 retornos al cuadrado correlacionados


```
r.n225<-ret.n225^2  
par(mfrow=c(1,1))  
acf(na.omit(r.n225))
```



```
pacf(na.omit(r.n225))
```




```
tsdisplay(na.omit(r.n225))
```




h:4 clusters de volatilidad

```
par(mfrow=c(1,1))  
plot(na.omit(ret.n225,main="retornos N225"))
```




```
plot(na.omit(r.n225,main="retornos al cuadrado N225"))
```



```
plot(na.omit(abs(ret.n225),main="retornos en absolutos N225"))
```


```
na.omit(abs(ret.n225), main = "retornos en absolutos N225")
```



podemos observar que tanto en los retornos, sus cuadrados y en valores absolutos es notable los clusters


```
par(mfrow=c(1,1))  
acf(na.omit(ret.n225,main="retornos N225"),lag.max = 500)
```


Series `na.omit(ret.n225, main = "retornos N225")`



```
acf(na.omit(r.n225,main="retornos al cuadrado N225"),lag.max = 500)
```

Series `na.omit(r.n225, main = "retornos al cuadrado N`




podemos observar significancia en lags alejados, se nota volatilidad por persistencia de autocorrelación la varianza puede estar condicionada a sus valores pasados lo que determina clusters

```

umbral3 <- quantile(na.omit(ret.n225),.95)
menor.umbr3<-as.numeric(ret.n225>umbral3)
agrupa.rets3<-menor.umbr3
as.ts(agrupa.rets3)

par(mfrow=c(1,1))
plot(agrupa.rets3)

```



LOS VALORES


SE AGLOMERAN

```

umb3<-function(IC){
  umbral3 <- quantile(na.omit(ret.n225),IC)
  menor.umbr3<-as.numeric(ret.n225>umbral3)
  agrupa.rets3<-menor.umbr3
  as.ts(agrupa.rets3)
  par(mfrow=c(1,1))
  plot(agrupa.rets3)
}

umb3(.99)

```




LOS VALORES SE AGLOMERAN

h:5 leptocurtosis


```
par(mfrow=c(1,1))
plot(density(na.omit(ret.n225, main="Densidad de los retornos del
N225")))
z3<-seq(-5,5,len=1000)
x3<-dnorm(z3,mean=mean(ret.n225,na.rm=T),sd=sd(ret.n225,na.rm=T))
lines(z3,x3,col='red',lty=2,lwd=2)
```

ult(x = na.omit(ret.n225, main = "Densidad de los retc



qq plot para determinar fat tails

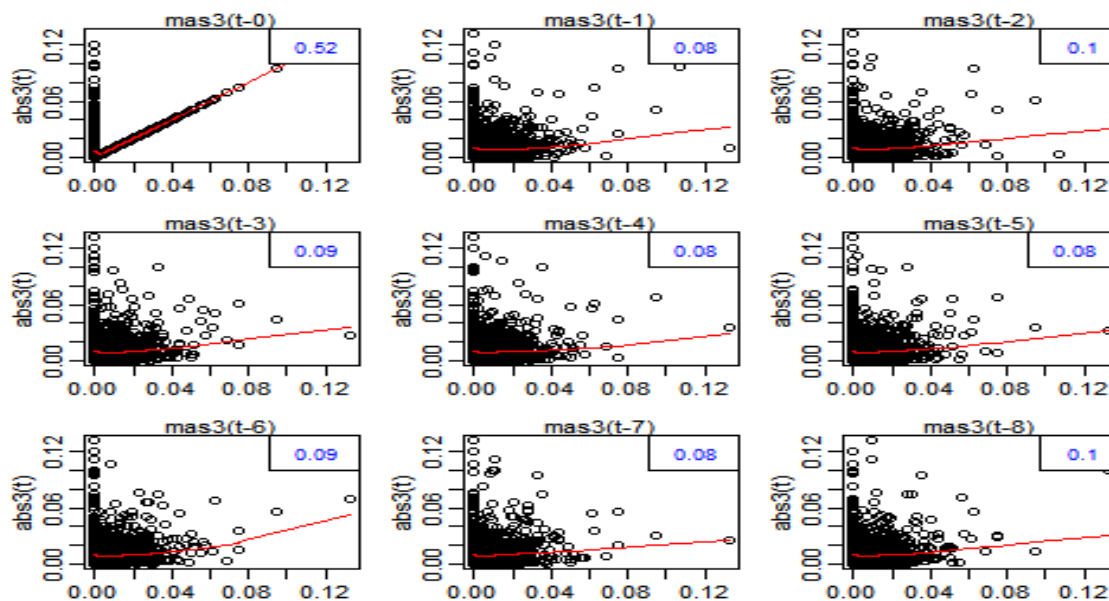
```
w3<-na.omit(coredata(ret.n225))
qqnorm(w3)
qqline(w3,col='red',lty=2)
```



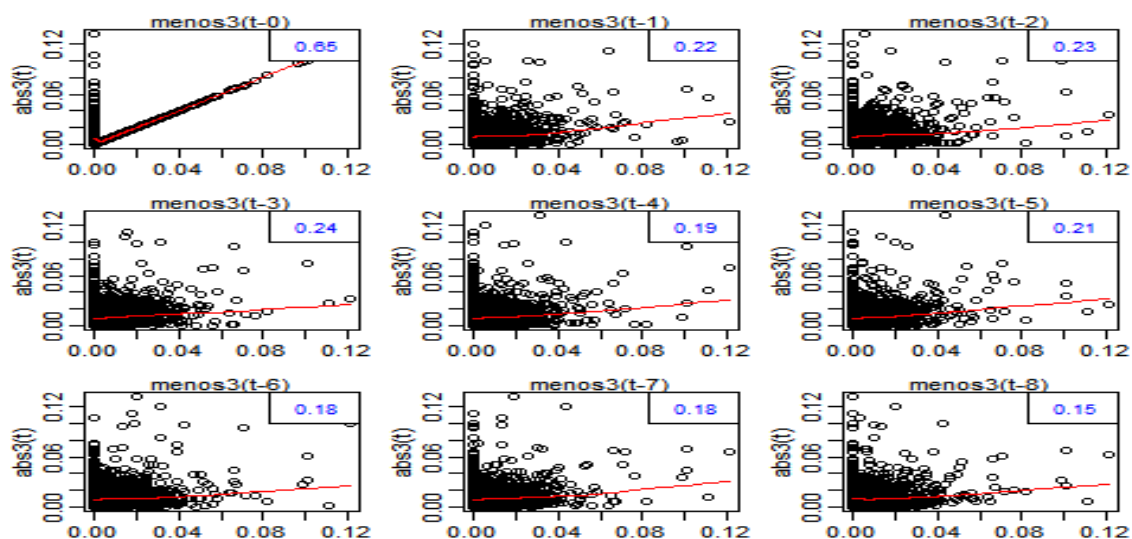
se observa informacisn a los extremos el cual es factor para tener colas anchas

h:6 leverage effect

```
library(astsa)
rets<-function(a){
  b<-diff(log(Ad(a)))
  return(b)}
}
dato3<-na.omit(ret.n225)
mas3<-apply.daily(dato3,function(a) max(a,0))
menos3<-apply.daily(dato3,function(a) -min(a,0))
abs3<-apply.daily(dato3,function(a) abs(a))
lag2.plot(mas3,abs3,8)
```



```
lag2.plot(menos3,abs3,8)
```





#choques negativos y positivos son asimétricos, los positivos hacen que los #retornos varíen menos que los negativos #justificación: Retornos se modelan mejor con ruido blanco débil o fuerte? #Ruido blanco Fuerte #Ya que su función de autocorrelación de los retornos logarítmicos, #no muestran significación en sus lags. #recordemos que independencia nos indica no correlación, en el cual esto no es el caso. #Con el Plot de la serie podemos ver cómo un valor elevado no sigue el comportamiento de su #valor o sus valores pasados, cae abruptamente como si fuera un arch sin tanta memoria.

EVALUANDO HECHOS ESTILIZADOS PARA AEX

h:1 precios de las acciones impredecibles


```
getSymbols("^AEX")
## [1] "AEX"

#generando variable
aex<-get("AEX")
#se seleccionan los precios ajustados
aex<-Ad(aex)
par(mfrow=c(2,1))
ret.aex<-diff(log(aex))
plot(ret.aex, main="retornos AEX")
plot(aex, main="AEX")
```




h:2 retornos no correlacionado


```
par(mfrow=c(1,1))  
acf(na.omit(ret.aex))
```



```
pacf(na.omit(ret.aex))
```




```
tsdisplay(ret.aex, lag.max = 20)
```




h:3 retornos al cuadrado correlacionados


```
r.aex<-ret.aex^2  
par(mfrow=c(1,1))  
acf(na.omit(r.aex))
```



```
pacf(na.omit(r.aex))
```




```
tsdisplay(na.omit(r.aex))
```




h:4 cloters de volatilidad


```
par(mfrow=c(1,1))  
plot(na.omit(ret.aex,main="retornos AEX"))
```



```
plot(na.omit(r.aex,main="retornos al cuadrado AEX"))
```




```
plot(na.omit(abs(ret.aex),main="retornos en absolutos AEX"))
```




podemos observar que tanto en los retornos, sus cuadrados y en valores absolutos es notable los cloters

```
par(mfrow=c(1,1))  
acf(na.omit(ret.aex,main="retornos AEX"),lag.max = 500)
```


```
acf(na.omit(r.aex,main="retornos al cuadrado AEX"),lag.max = 500)
```



podemos observar significancia en lags alejados, se nota volatilidad por persistencia de autocorrelación #la varianza puede estar condicionada a sus valores pasados lo que determina clusters

```
umbral4 <- quantile(na.omit(ret.aex),.95)
menor.umbr4<-as.numeric(ret.aex>umbral4)
agrupa.rets4<-menor.umbr4
as.ts(agrupa.rets4)


par(mfrow=c(1,1))
plot(agrupa.rets4)
```



LOS VALORES SE AGLOMERAN

```
umb4<-function(x){
  umbral4 <- quantile(na.omit(ret.aex),x)
  menor.umbr4<-as.numeric(ret.aex>umbral4)
  agrupa.rets4<-menor.umbr4
  as.ts(agrupa.rets4)
  par(mfrow=c(1,1))
  plot(agrupa.rets4)
}


umb4(.99)
```



LOS VALORES SE AGLOMERAN h:5 leptocurtosis

```
par(mfrow=c(1,1))
plot(density(na.omit(ret.aex, main="Densidad de los retornos del AEX")))
z4<-seq(-5,5,len=1000)
x4<-dnorm(z4,mean=mean(ret.aex,na.rm=T),sd=sd(ret.aex,na.rm=T))
lines(z4,x4,col='red',lty=2,lwd=2)
```


```
ault(x = na.omit(ret.aex, main = "Densidad de los reto
```



qq plot para

determinar fat tails

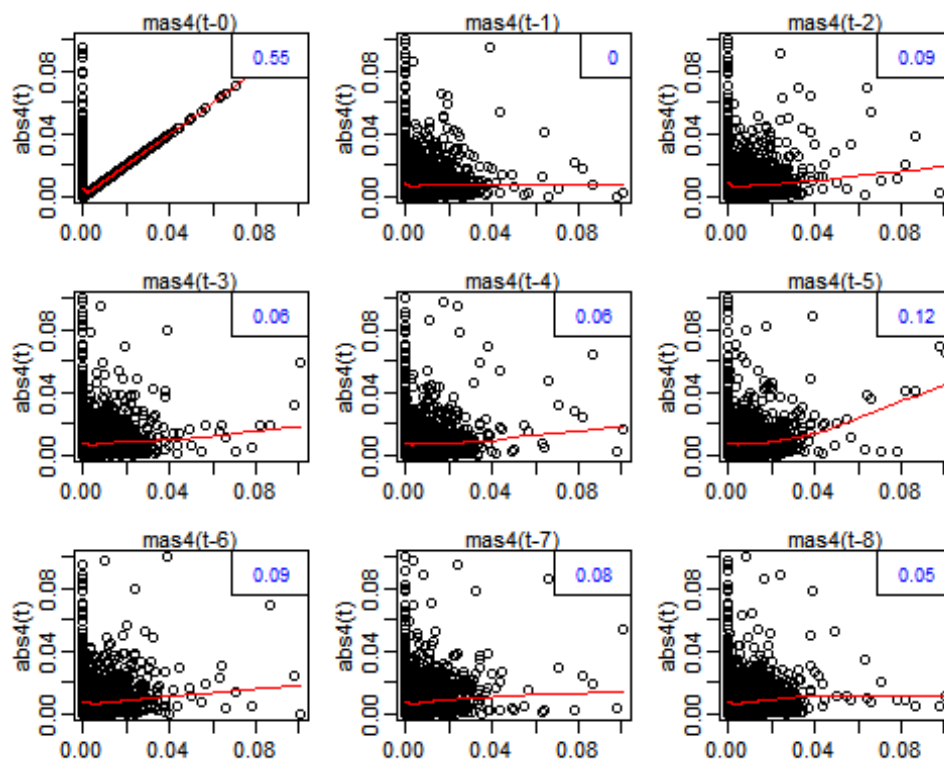
```
w4<-na.omit(coredata(ret.aex))
qqnorm(w4)
qqline(w4,col='red',lty=2)
```



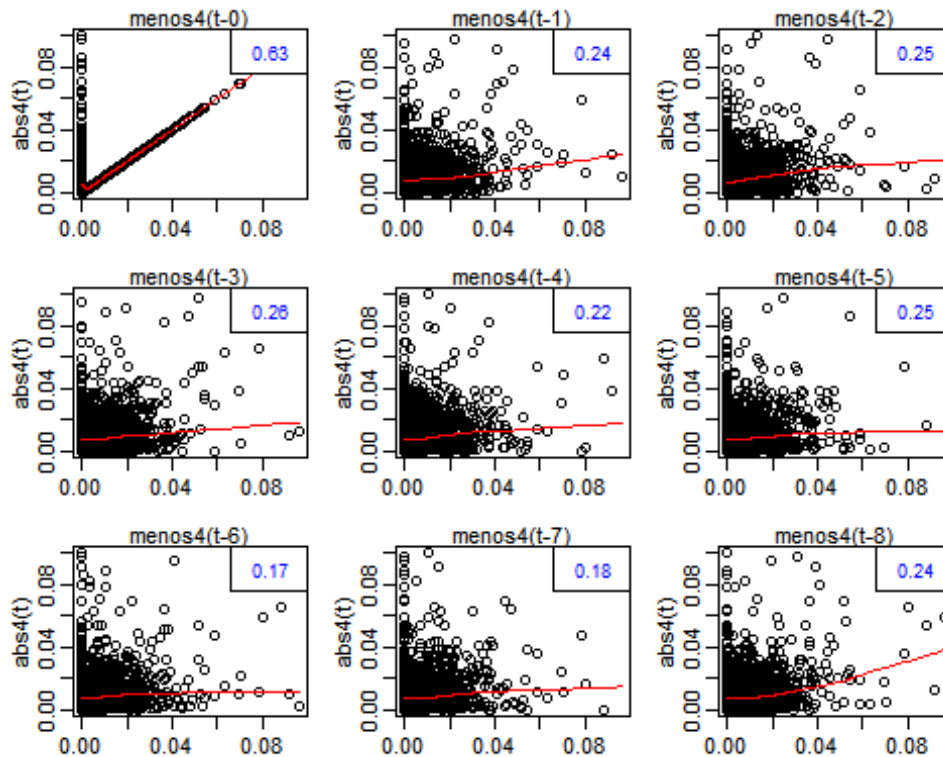
se observa informacisn a los extremos el cual es factor para tener colas anchas

h:6 leverage effect

```
library(astsa)
rets<-function(a){
  b<-diff(log(Ad(a)))
  return(b)
}
dato4<-na.omit(ret.aex)
mas4<-apply.daily(dato4,function(a) max(a,0))
menos4<-apply.daily(dato4,function(a) -min(a,0))
abs4<-apply.daily(dato4,function(a) abs(a))
lag2.plot(mas4,abs4,8)
```



```
lag2.plot(menos4,abs4,8)
```



#choques negativos y positivos son asimetricos, los positivos hacen que los #retornos varien menos que los negativos #justificaci??n:??Retornos se modelan mejor con ruido blanco debil o fuerte? #Ruido blanco Debil #Ya que su funci??n de autocorrelaci?? de los retornos logaritmicos, # #muestran significancia en sus lags. #recordemos que independencia nos indica no correlaci??, en el cual est?? no es el caso. #Con el Plot de la serie podemos ver como un valor elevado sigue el comportamiento de su #valor o sus valores pasados.

EVALUANDO HECHOS ESTILIZADOS PARA MXX

h:1 precios de las acciones impredecibles

```
getSymbols("^MXX")
```

```
## [1] "MXX"
```

```
#generando variable
```

```
mxx<-get("MXX")
```


```
#se seleccionan los precios ajustados
```

```
mxx <- Adj(mxx)
```


```
par(mfrow=c(1,1))
```

```
ret.mxx<-diff(log(mxx))
```

```
plot(ret.mxx, main="retornos MXX")
```




```
plot(mxx, main="MXX")
```




h:2 retornos

no correlacionado


```
par(mfrow=c(1,1))
acf(na.omit(ret.mxx))
```



```
pacf(na.omit(ret.mxx))
```




```
tsdisplay(ret.mxx, lag.max = 20)
```




h:3 retornos al

cuadrado correlacionados


```
par(mfrow=c(1,1))
r.mxx<-ret.mxx^2
acf(na.omit(r.mxx))
```



```
pacf(na.omit(r.mxx))
```




```
tsdisplay(na.omit(r.mxx))
```




h:4 clusters de volatilidad

```
par(mfrow=c(1,1))
plot(na.omit(ret.mxx,main="retornos MXX"))
```




```
plot(na.omit(r.mxx,main="retornos al cuadrado MXX"))
```

```
na.omit(r.mxx, main = "retornos al cuadrado MXX")
```



```
plot(na.omit(abs(ret.mxx),main="retornos en absolutos MXX"))
```


```
a.omit(abs(ret.mxx), main = "retornos en absolutos MXX")
```



podemos observar que tanto en los retornos, sus cuadrados y en valores absolutos es notable los clusters

```
par(mfrow=c(1,1))
acf(na.omit(ret.mxx,main="retornos MXX"),lag.max = 500)
```


Series `na.omit(ret.mxx, main = "retornos MXX")`



```
acf(na.omit(r.mxx,main="retornos al cuadrado MXX"),lag.max = 500)
```




```
series na.omit(r.mxx, main = "retornos al cuadrado N
```



#podemos observar significancia en lags alejados, se nota volatilidad por persistencia de autocorrelacion #la varianza puede estar condicionada a sus valores pasados lo que determina clusters

```
umbral5 <- quantile(na.omit(ret.mxx), .95)
menor.umbr5 <- as.numeric(ret.mxx > umbral5)
agrupa.rets5 <- menor.umbr5
as.ts(agrupa.rets5)


par(mfrow=c(1,1))
plot(agrupa.rets5)
```



LOS VALORES SE AGLOMERAN

```
umb5 <- function(x){
  umbral5 <- quantile(na.omit(ret.mxx), x)
  menor.umbr5 <- as.numeric(ret.mxx > umbral5)
  agrupar.rets5 <- menor.umbr5
  as.ts(agrupar.rets5)
  par(mfrow=c(1,1))
  plot(agrupar.rets5)
}


umb5(.99)
```



h:5 leptocurtosis

```
par(mfrow=c(1,1))
plot(density(na.omit(ret.mxx, main="Densidad de los retornos del MXX")))
z5<-seq(-5,5,len=1000)
x5<-dnorm(z5,mean=mean(ret.mxx,na.rm=T),sd=sd(ret.mxx,na.rm=T))
lines(z5,x5,col='red',lty=2,lwd=2)
```


ult(x = na.omit(ret.mxx, main = "Densidad de los retc



q

q plot para determinar fat tails

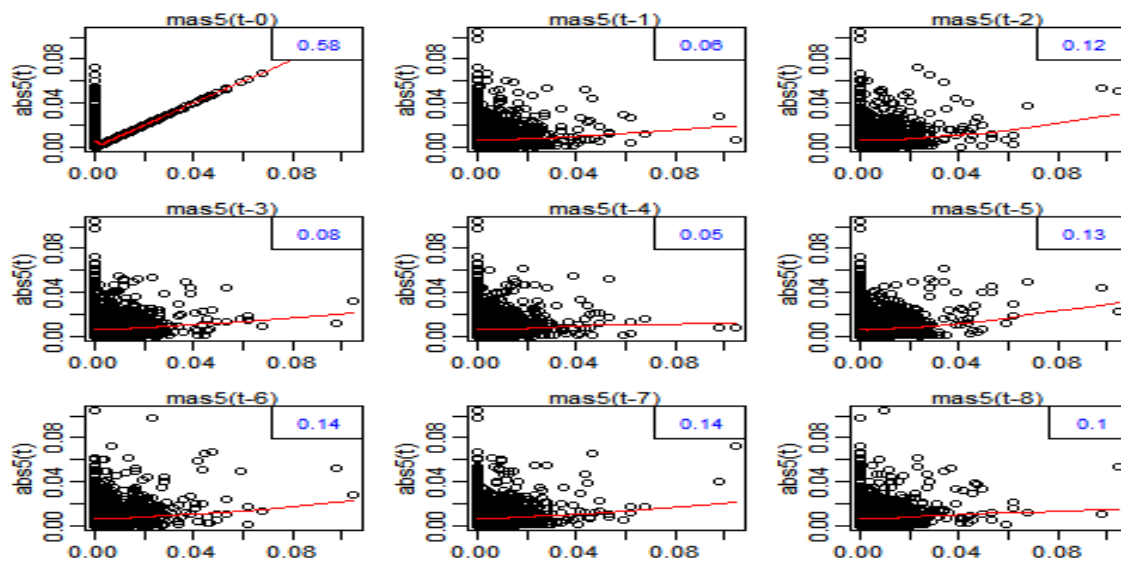
```
w5<-na.omit(coredata(ret.mxx))
qqnorm(w5)
qqline(w5,col='red',lty=2)
```



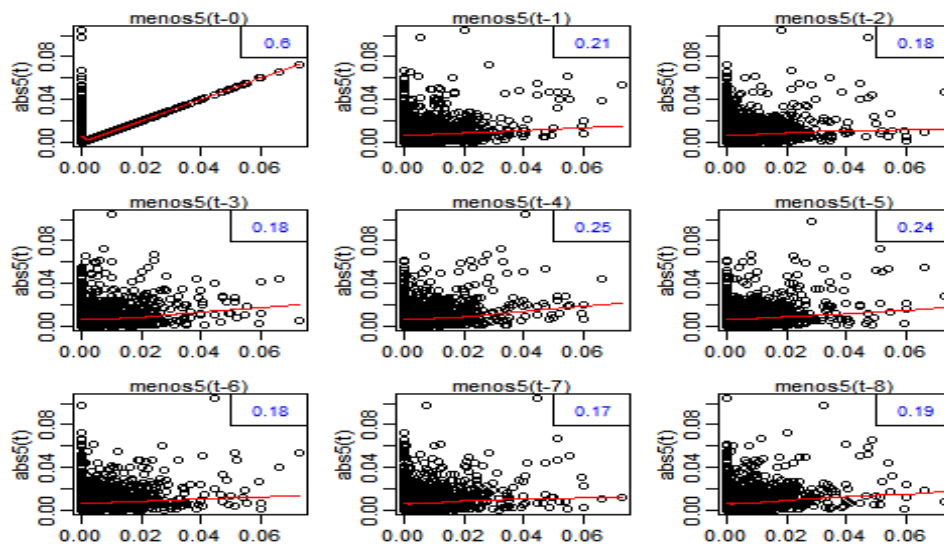
se observa informacisn a los extremos el cual es factor para tener colas anchas

h:6 leverage effect

```
library(astsa)
rets<-function(a){
  b<-diff(log(Ad(a)))
  return(b)}
}
dato5<-na.omit(ret.mxx)
mas5<-apply.daily(dato5,function(a) max(a,0))
menos5<-apply.daily(dato5,function(a) -min(a,0))
abs5<-apply.daily(dato5,function(a) abs(a))
lag2.plot(mas5,abs5,8)
```



```
lag2.plot(menos5,abs5,8)
```



#choques negativos y positivos son asimetricos, los positivos hacen que los #retornos varien menos que los negativos #justificaci??n:??Retornos se modelan mejor con

ruido blanco debil o fuerte? #Ruido blanco Debil #Ya que su funci??n de autocorrelaci?? de los retornos logaritmicos, # #muestran significacia en sus lags. #recoredemos que independencia nos indica no correlaci??, en el cual est?? no es el caso. #Con el Plot de la serie podemos ver como un valor elevado sigue el comportamiento de su #valor o sus valores pasados.

EVALUANDO HECHOS ESTILIZADOS PARA FCHI

h:1 precios de las acciones impredecibles

```
getSymbols("^FCHI")
```

```
## [1] "FCHI"
```

```
#generando variable
```

```
fchi<-get("FCHI")
```


```
#se seleccionan los precios ajustados
```

```
fchi <- Adj(fchi)
```


```
par(mfrow=c(1,1))
```

```
ret.fchi<-diff(log(fchi))
```

```
plot(ret.fchi, main="retornos FCHI")
```




```
plot(fchi, main="FCHI")
```




h:2 retornos no correlacionado


```
par(mfrow=c(1,1))  
acf(na.omit(ret.fchi))
```



```
pacf(na.omit(ret.fchi))
```




```
tsdisplay(ret.fchi, lag.max = 20)
```




h:3 retornos al cuadrado correlacionados


```
par(mfrow=c(1,1))  
r.fchi<-ret.fchi^2  
acf(na.omit(r.fchi))
```



```
pacf(na.omit(r.fchi))
```




```
tsdisplay(na.omit(r.fchi))
```




h:4 clusters de volatilidad

```
par(mfrow=c(1,1))
plot(na.omit(ret.fchi),main="retornos FCHI")
```




```
plot(na.omit(r.fchi,main="retornos al cuadrado FCHI"))
```

```
na.omit(r.fchi, main = "retornos al cuadrado FCHI")
```



```
plot(na.omit(abs(ret.fchi),main="retornos en absolutos FCHI"))
```


```
na.omit(abs(ret.fchi), main = "retornos en absolutos FCHI")
```



podemos observar que tanto en los retornos, sus cuadrados y en valores absolutos es notable los clusters


```
par(mfrow=c(1,1))
acf(na.omit(ret.fchi,main="retornos FCHI"),lag.max = 500)
```

Series na.omit(ret.fchi, main = "retornos FCHI")



```
acf(na.omit(r.fchi,main="retornos al cuadrado FCHI"),lag.max = 500)
```


Series na.omit(r.fchi, main = "retornos al cuadrado F



podemos observar significancia en lags alejados, se nota volatilidad por persistencia de autocorrelación #la varianza puede estar condicionada a sus valores pasados lo que determina clusters

```
umbral6 <- quantile(na.omit(ret.fchi),.95)
menor.umbr6<-as.numeric(ret.fchi>umbral6)
agrupa.rets6<-menor.umbr6
as.ts(agrupa.rets6)

par(mfrow=c(1,1))
plot(agrupa.rets6)
```





LOS VALORES

SE AGLOMERAN

```
umb6<-function(x){
  umbral6 <- quantile(na.omit(ret.fchi),x)
  menor.umbr6<-as.numeric(ret.fchi>umbral6)
  agrupa.rets6<-menor.umbr6
  as.ts(agrupa.rets6)
  par(mfrow=c(1,1))
  plot(agrupa.rets6)
}


umb6(.99)
```



h:5 leptocurtosis


```
par(mfrow=c(1,1))
plot(density(na.omit(ret.fchi, main="Densidad de los retornos del
FCHI"))))
z6<-seq(-5,5,len=1000)
x6<-dnorm(z6,mean=mean(ret.fchi,na.rm=T),sd=sd(ret.fchi,na.rm=T))
lines(z6,x6,col='red',lty=2,lwd=2)
```

```
plot(x = na.omit(ret.fchi), main = "Densidad de los reto
```



qq plot para determinar fat tails

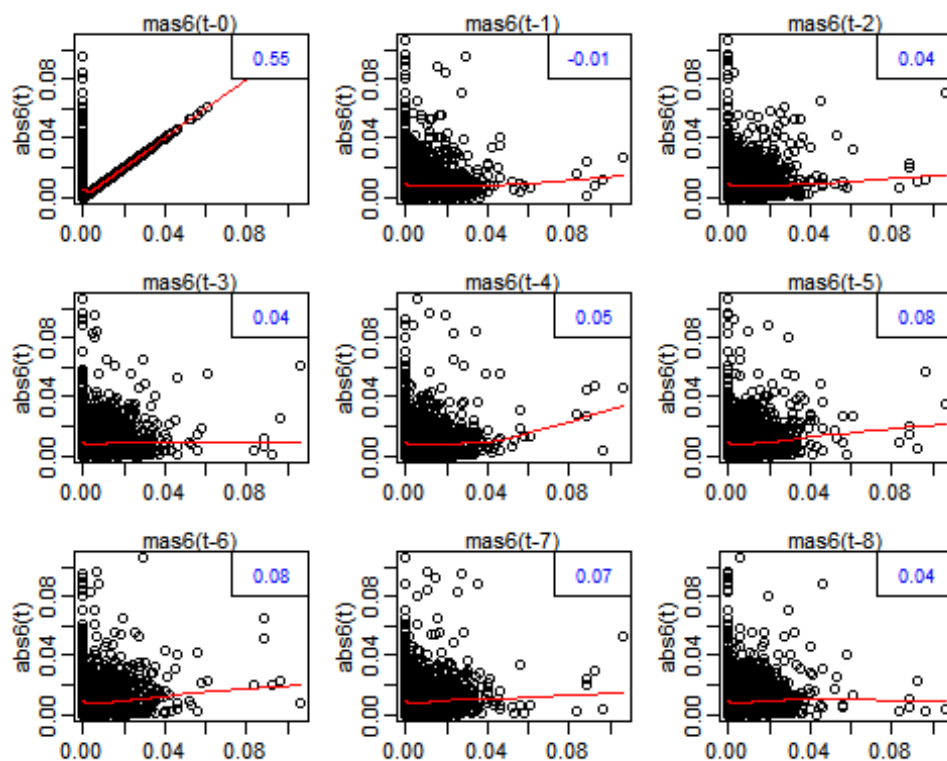
```
w6<-na.omit(coredata(ret.fchi))
qqnorm(w6)
qqline(w6,col='red',lty=2)
```



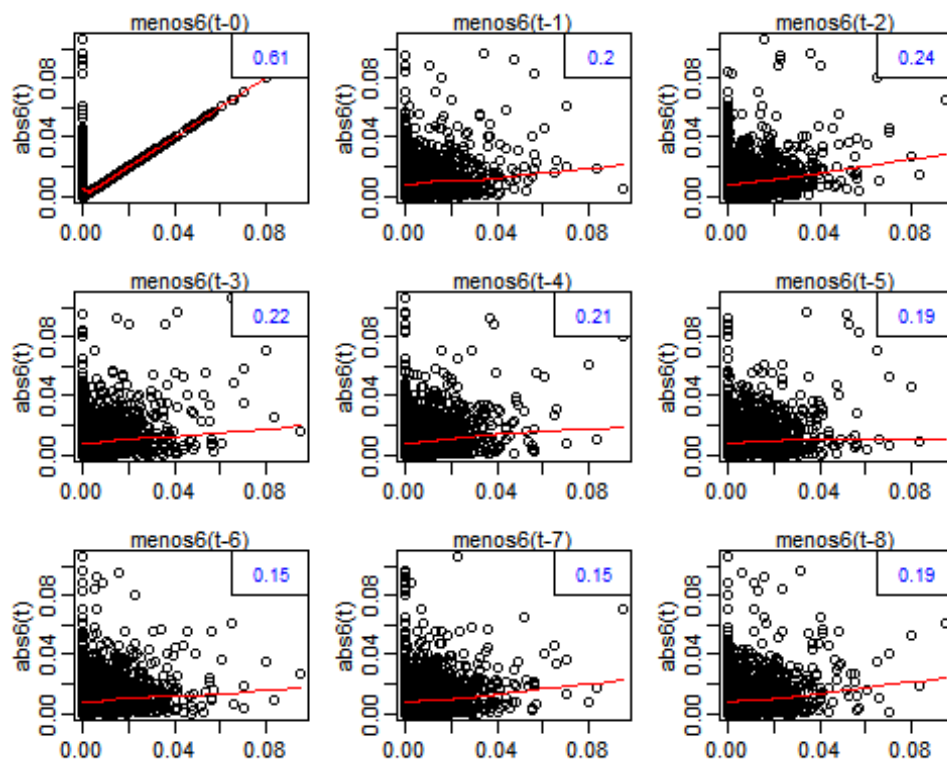
se observa informacisn a los extremos el cual es factor para tener colas anchas

h:6 leverage effect

```
library(astsa)
rets<-function(a){
  b<-diff(log(Ad(a)))
  return(b)
}
dato6<-na.omit(ret.fchi)
mas6<-apply.daily(dato6,function(a) max(a,0))
menos6<-apply.daily(dato6,function(a) -min(a,0))
abs6<-apply.daily(dato6,function(a) abs(a))
lag2.plot(mas6,abs6,8)
```



`lag2.plot(menos6,abs6,8)`



#choques negativos y positivos son asimetricos, los positivos hacen que los #retornos varien menos que los negativos #justificaci??n:??Retornos se modelan mejor con ruido blanco debil o fuerte? #Ruido blanco Debil #Ya que su funci??n de autocorrelaci?? de los retornos logaritmicos, # #muestran significancia en sus lags. #recoremos que independencia nos indica no correlaci??, en el cual est?? no es el caso. #Con el Plot de la serie podemos ver como un valor elevado sigue el comportamiento de su #valor o sus valores pasados.

FIN EJERCICIO 1

Especificaciones GARCH en R

```
require(rugarch)
```

```
## Loading required package: rugarch
## Loading required package: parallel
##
## Attaching package: 'rugarch'
##
## The following object is masked from 'package:stats':
##
##      sigma
```

GARCH(1,1)

```
mod.med <- list(armaOrder = c(0, 0), include.mean = F)
mod.var1 <- list(model = "sGARCH", garchOrder = c(1, 1))
spec1 <- ugarchspec(variance.model = mod.var1,
                    mean.model = mod.med)
```

```
spec1
```

```
##
## *-----*
## *          GARCH Model Spec          *
## *-----*
##
## Conditional Variance Dynamics
## -----
## GARCH Model      : sGARCH(1,1)
## Variance Targeting : FALSE
##
## Conditional Mean Dynamics
## -----
## Mean Model       : ARFIMA(0,0,0)
## Include Mean     : FALSE
## GARCH-in-Mean    : FALSE
##
## Conditional Distribution
## -----
## Distribution : norm
```

```
## Includes Skew      : FALSE
## Includes Shape     : FALSE
## Includes Lambda    : FALSE
```

GARCH(1,2)

```
mod.med <- list(armaOrder = c(0, 0), include.mean = F)
mod.var2 <- list(model = "sGARCH", garchOrder = c(1, 2))
spec2 <- ugarchspec(variance.model = mod.var2,
                    mean.model = mod.med)
```

```
spec2
```

```
##
## *-----*
## *      GARCH Model Spec      *
## *-----*
##
## Conditional Variance Dynamics
## -----
## GARCH Model      : sGARCH(1,2)
## Variance Targeting : FALSE
##
## Conditional Mean Dynamics
## -----
## Mean Model       : ARFIMA(0,0,0)
## Include Mean     : FALSE
## GARCH-in-Mean    : FALSE
##
## Conditional Distribution
## -----
## Distribution : norm
## Includes Skew  : FALSE
## Includes Shape : FALSE
## Includes Lambda : FALSE
```

GARCH(2,1)

```
mod.med <- list(armaOrder = c(0, 0), include.mean = F)
mod.var3 <- list(model = "sGARCH", garchOrder = c(2, 1))
spec3 <- ugarchspec(variance.model = mod.var3,
                    mean.model = mod.med)
```

```
spec3
```

```
##
## *-----*
## *      GARCH Model Spec      *
## *-----*
##
## Conditional Variance Dynamics
## -----
## GARCH Model      : sGARCH(2,1)
## Variance Targeting : FALSE
```

```
##
## Conditional Mean Dynamics
## -----
## Mean Model      : ARFIMA(0,0,0)
## Include Mean    : FALSE
## GARCH-in-Mean   : FALSE
##
## Conditional Distribution
## -----
## Distribution : norm
## Includes Skew : FALSE
## Includes Shape : FALSE
## Includes Lambda : FALSE
```

ARCH(1)

```
mod.med <- list(armaOrder = c(0, 0), include.mean = F)
mod.var4 <- list(model = "sGARCH", garchOrder = c(1, 0))
spec4 <- ugarchspec(variance.model = mod.var4,
                    mean.model = mod.med)
```

```
spec4
```

```
##
## *-----*
## *      GARCH Model Spec      *
## *-----*
##
## Conditional Variance Dynamics
## -----
## GARCH Model      : sGARCH(1,0)
## Variance Targeting : FALSE
##
## Conditional Mean Dynamics
## -----
## Mean Model      : ARFIMA(0,0,0)
## Include Mean    : FALSE
## GARCH-in-Mean   : FALSE
##
## Conditional Distribution
## -----
## Distribution : norm
## Includes Skew : FALSE
## Includes Shape : FALSE
## Includes Lambda : FALSE
```

ARCH(2)

```
mod.med <- list(armaOrder = c(0, 0), include.mean = F)
mod.var5 <- list(model = "sGARCH", garchOrder = c(2, 0))
spec5 <- ugarchspec(variance.model = mod.var5,
                    mean.model = mod.med)
```

```
spec5
```

```
##
## *-----*
## *      GARCH Model Spec      *
## *-----*
##
## Conditional Variance Dynamics
## -----
## GARCH Model      : sGARCH(2,0)
## Variance Targeting : FALSE
##
## Conditional Mean Dynamics
## -----
## Mean Model       : ARFIMA(0,0,0)
## Include Mean      : FALSE
## GARCH-in-Mean     : FALSE
##
## Conditional Distribution
## -----
## Distribution : norm
## Includes Skew  : FALSE
## Includes Shape : FALSE
## Includes Lambda : FALSE
```

IGARCH(1,1)

```
mod.med <- list(armaOrder = c(0, 0), include.mean = F)
mod.var6 <- list(model = "iGARCH", garchOrder = c(1, 1))
spec6 <- ugarchspec(variance.model = mod.var6,
                    mean.model = mod.med)
```

```
spec6
```

```
##
## *-----*
## *      GARCH Model Spec      *
## *-----*
##
## Conditional Variance Dynamics
## -----
## GARCH Model      : iGARCH(1,1)
## Variance Targeting : FALSE
##
## Conditional Mean Dynamics
## -----
## Mean Model       : ARFIMA(0,0,0)
## Include Mean      : FALSE
## GARCH-in-Mean     : FALSE
##
## Conditional Distribution
## -----
## Distribution : norm
## Includes Skew  : FALSE
```

```
## Includes Shape : FALSE
## Includes Lambda : FALSE
```

Simulacisn con las especificaciones GARCH

```
require(rugarch)
```


GARCH(1,1)

```
par(mfrow=c(2,1))
## Con Cuarto Momento Finito:
prmtrs1 <- list(omega=1, alpha1 = 0.4, beta1 = 0.2)
spec1 <- ugarchspec(variance.model = mod.var1,
                    mean.model = mod.med,
                    fixed.pars = prmtrs1)

garch.sim1 <- ugarchpath(spec1, n.sim = 500)
plot(garch.sim1, which = 2)

## Sin Cuarto Momento Finito
prmtrs1 <- list(omega=1, alpha1 = 0.6, beta1 = 0.2)
spec1 <- ugarchspec(variance.model = mod.var1,
                    mean.model = mod.med,
                    fixed.pars = prmtrs1)


garch.sim1 <- ugarchpath(spec1, n.sim = 500)
plot(garch.sim1, which = 2)
```



GARCH(1,2)

```
par(mfrow=c(1,1))
prmtrs2 <- list(omega=1, alpha1 = 0.2, beta1 = 0.4, beta2 = 0.2)
spec2 <- ugarchspec(variance.model = mod.var2,
                    mean.model = mod.med,
                    fixed.pars = prmtrs2)


garch.sim2 <- ugarchpath(spec2, n.sim = 500)
plot(garch.sim2, which = 2)
```



GARCH(2,1)

```
par(mfrow=c(1,1))
prmtrs3 <- list(omega=1, alpha1 = 0.2, alpha2 = 0.23, beta1 = 0.5)
spec3 <- ugarchspec(variance.model = mod.var3,
                    mean.model = mod.med,
                    fixed.pars = prmtrs3)

garch.sim3 <- ugarchpath(spec3, n.sim = 500)
plot(garch.sim3, which = 2)
```




ARCH(1)

```
par(mfrow=c(2,1))
# Con Cuarto Momento Finito
prmtrs4 <- list(omega=1, alpha1 = 0.36)
spec4 <- ugarchspec(variance.model = mod.var4,
                     mean.model = mod.med,
                     fixed.pars = prmtrs4)

garch.sim4 <- ugarchpath(spec4, n.sim = 500)
plot(garch.sim4, which = 2)

# Sin Cuarto Momento Finito
prmtrs4 <- list(omega=1, alpha1 = 0.8)
spec4 <- ugarchspec(variance.model = mod.var4,
                     mean.model = mod.med,
                     fixed.pars = prmtrs4)

garch.sim4 <- ugarchpath(spec4, n.sim = 500)
plot(garch.sim4, which = 2)
```



ARCH(2)


```
par(mfrow=c(2,1))
# Con Cuarto Momento Finito
prmtrs5 <- list(omega=1, alpha1 = 0.2, alpha2 = 0.5)
```

```
spec5 <- ugarchspec(variance.model = mod.var5,
                    mean.model = mod.med,
                    fixed.pars = prmtrs5)

garch.sim5 <- ugarchpath(spec5, n.sim = 500)
plot(garch.sim5, which = 2)

# Sin Cuarto Momento Finito
prmtrs5 <- list(omega=1, alpha1 = 0.4, alpha2 = 0.5)
spec5 <- ugarchspec(variance.model = mod.var5,
                    mean.model = mod.med,
                    fixed.pars = prmtrs5)


garch.sim5 <- ugarchpath(spec5, n.sim = 500)
plot(garch.sim5, which = 2)
```



IGARCH(1,1)

```
par(mfrow=c(1,1))
prmtrs6 <- list(omega=1, alpha1 = 0.9)
spec6 <- ugarchspec(variance.model = mod.var6,
                    mean.model = mod.med,
                    fixed.pars = prmtrs6)

garch.sim6 <- ugarchpath(spec6, n.sim = 500)
plot(garch.sim6, which = 2)
```




Estacionariedad

EJERCICIO 4

1

```
simula <- function(n.sim){
  alpha <- rnorm(n.sim)
  a<- log( alpha ^ 2 )
  mu <- cumsum(a) / seq_along(a)
  err.ind <- a - mu
  err.total <- sum(err.ind^2)
  sigma.n <- sqrt(err.total) / seq_along(a)
  upper <- mu + 1.96*sigma.n
  lower <- mu - 1.96*sigma.n
  plot(mu, type = 'l', col = "blue")
  lines(upper, col = "red")
  lines(lower, col = "red")
}
simula(10000)
```



```

z<-rnorm(10^4)
estim<-mean(2*z^2+.9)
estim< 1

## [1] FALSE

decide<-function(n.sim,alpha,beta){
  z<-rnorm(n.sim)
  estim<-mean(alpha*z^2+beta)
  estim< 1
}
decide(1000,.2,.3)

## [1] TRUE

```

CAMBIANDO VALORES Y ORDENES DEL GARCH


SE PROGRAMA FUNCION EN EL CUAL SOLO SE DEBERA CAMBIAR EL ORDEN Y VALORES DEL GARCH Y SUS PARAMETROS

```

alpha=c(2,1)
beta=c(0)
garch_matrix<-function(alpha,beta){
  renglones <- rbind(c(alpha*rnorm(1)^2, beta*rnorm(1)^2),
                    cbind(diag(1,length(alpha)-1,length(beta)),
                          diag(0,length(alpha)-1,length(alpha))),
                    c(alpha, beta), cbind(diag(0,length(beta)-
1,length(alpha)),
                                         diag(1,length(beta)-
1,length(beta))))
  A <- matrix(renglones, nrow = length(alpha)+length(beta))
}
garch_matrix(alpha,beta)

matrices <- rerun(500, garch_matrix(alpha, beta))
prods <- accumulate(matrices, `*`)
normas <- map_dbl(prods, norm)
lyapunov <- log(normas) / seq_along(normas)
plot(lyapunov, type = "l")

```



El resultado del lyapunov varía según el modelo que se analice, notamos que para 500 simulaciones el valor tiende a estar entre 0.2 y 0.3.

Momentos superiores

EJERCICIO4

1

Nota μ_4 es una variable aleatoria y su cuarto momento es 3

```
mom.cuatro<-function(mu4,alpha,beta,w) {
  estim<-mu4*((w^2*(1-alpha+beta))/((1-alpha-beta)*(1-mu4)*alpha^2-
beta^2-2*alpha*beta))
  estim<-alpha+beta
  mu4>0 & estim!=1 & w!=0
}

mom.cuatro(3,.2,.8,2)
```

```
## [1] FALSE
```

El método de Monte Carlo te dará valores que convergen por lo tanto en cuanto más elevada sea la simulación los valores convergen pudiendo violar las restricciones.


FIN DEL 1

2

```
library(purrr)
alpha<-c(.1,.3)
beta<-c(.2,.5)

garch_matrix<-function(alpha,beta){
  renglones <- rbind(c(alpha*rnorm(1)^2, beta*rnorm(1)^2),
                    cbind(diag(1,length(alpha)-1,length(beta)),
                          diag(0,length(alpha)-1,length(alpha))),
                    c(alpha, beta), cbind(diag(0,length(beta)-
1,length(alpha)),
                                          diag(1,length(beta)-
1,length(beta))))
  A <- matrix(renglones, nrow = length(alpha)+length(beta))
  A.2 <- kronecker(A,A)
}

matrices <- rerun(500, garch_matrix(alpha, beta))
prods <- accumulate(matrices, `*`)
normas <- map_dbl(prods, norm)
a<- log(normas) / seq_along(normas)
plot(a)
```



```
rho <- max(abs(eigen(garch_matrix(alpha, beta))$values))
rho
## [1] 1.215237
```

si llevas al limite la la esperanza de las sumo de los productor (kronecker) tiende a cero, lo que equivale a un radio espectral menor a uno.

No es menor a uno el radio espectral dado el modelo.

FIN